Relatório Geral de Análise

Inteligência de Varejo: Impacto da Inflação e Eficiência Logística no PDV

Projeto: inteligencia-varejo-dinamica-consumo **Período analisado:** Janeiro/2016 – Agosto/2018 **Data do relatório:** Março/2026 **Autor:** Rael **Stack:** Python 3.11 | Pandas | Scikit-learn | Seaborn | Matplotlib | IBGE/SIDRA API

---

1. Contexto e Objetivo

Este projeto analisa como variáveis macroeconômicas (inflação/IPCA) e falhas operacionais (ruptura logística) impactam o **Sell-out** — a venda real de produtos ao consumidor final. A análise foi conduzida sobre o dataset público da Olist, a maior plataforma de e-commerce B2B do Brasil, combinado com dados oficiais do IBGE coletados via API REST em tempo real.

Questões de negócio investigadas

1. A inflação (IPCA) impacta diretamente o volume de vendas no curto prazo?
2. Existe um "Custo Nordeste" mensurável em termos de logística e frete?
3. Quais são os segmentos de clientes com maior potencial e maior risco?
4. É possível prever ruptura logística e insatisfação do cliente com dados operacionais?

Termos de negócio utilizados

- **Ruptura:** falha na promessa de entrega (delivery_delay_days > 0)
- **Lead Time:** dias entre a compra e o recebimento pelo cliente
- **Sell-out:** saída efetiva de produtos para o consumidor final

---

2. Fontes de Dados e Metodologia

2.1 Datasets utilizados

Fonte	Descrição	Volume
`olist_orders_dataset.csv`	Status e datas dos pedidos	96.478 pedidos entregues

`olist_order_items_dataset.csv`	Preço, frete e produto por pedido	—
`olist_order_reviews_dataset.csv`	Nota de satisfação do cliente (1–5★)	—
`olist_customers_dataset.csv`	Estado e ID único do cliente	—
`olist_products_dataset.csv`	Categoria e atributos do produto	—
`product_category_name_translation.csv`	Tradução PT→EN das categorias	—
IBGE/SIDRA (API)	IPCA mensal — Tabela 1737	Jan/2016–Dez/2018

2.2 Pipeline ETL

O pipeline de dados segue três etapas:

Extração: leitura dos CSVs brutos e consumo da API REST do IBGE. A API retorna o IPCA em formato JSON, parseado e normalizado para DataFrame.

Transformação: filtro de integridade (apenas pedidos com status `delivered`), conversão de colunas de data para `datetime`, criação de KPIs logísticos (`delivery_delay_days`, `lead_time_days`), geração de chave temporal `AnoMes` no padrão YYYY-MM para join com o IPCA, e encoding de variáveis categóricas para Machine Learning.

Carga: consolidação em um DataFrame analítico único via cinco operações de merge (orders + customers + reviews + order_totals + products + category_map), resultando em 96.478 registros com 19 colunas.

---

3. Análise Exploratória — Logística e Inflação (Notebook 01)

3.1 Custo Pernambuco vs São Paulo

Indicador	Pernambuco (PE)	São Paulo (SP)	Diferença
Lead Time médio	17,96 dias	8,30 dias	**+116%**
Frete médio	R$ 35,83	R$ 17,33	**+107%**

A disparidade reflete a concentração de sellers em São Paulo (origem da maioria dos produtos) e a desvantagem logística estrutural do Nordeste. Para uma empresa como a CX

Trade, sediada em Recife/PE, esse dado é diretamente aplicável: clientes locais vivenciam lead times dobrados, o que eleva o risco de ruptura e insatisfação.

3.2 Impacto da Ruptura na Satisfação

Status de Entrega	Review Score médio
No Prazo	**4,29★**
Atrasado (Ruptura)	**2,27★**
Diferença	**-2,02 pontos (47% de queda)**

Um atraso na entrega quase divide a nota de satisfação ao meio. Esse resultado confirma que a ruptura logística é o principal destruidor de experiência do cliente no e-commerce brasileiro.

3.3 IPCA × Volume de Vendas

O cruzamento do IPCA mensal (IBGE) com o volume de pedidos Olist não revelou correlação direta no curto prazo. As oscilações no volume de vendas são mais bem explicadas por crescimento orgânico do e-commerce e sazonalidade — especialmente o pico de novembro (Black Friday), visível no gráfico de eixo duplo.

---

4. Análise Avançada — Segmentação e Comportamento (Notebook 02)

4.1 Segmentação RFM

Base de **93.358 clientes únicos** segmentada por Recência, Frequência e Valor Monetário (scoring Q1–Q4).

Segmento	Clientes	%	Ticket Médio	Perfil
Campeões	23.491	25,1%	R$ 147	Comprou recente e várias vezes
Clientes Recentes	23.356	25,0%	R$ 138	Comprou recente, baixa freq.
Em Risco	23.188	24,8%	R$ 143	Frequente mas sumiu
Potencial	17.423	18,6%	R$ 148	Perfil intermediário
Perdidos	5.900	6,3%	R$ 138	Não compra há muito tempo

Ponto de atenção: quase **50% da base** (Em Risco + Perdidos = 29.088 clientes) representa receita latente não capturada. Estratégias de reativação via e-mail marketing, cupons ou

personalização podem recuperar parte desse volume sem custo de aquisição.

4.2 Performance por Categoria de Produto

Todas as 10 categorias mais vendidas mantêm review score acima de 4,0★, sinalizando operação saudável nas categorias de maior volume.

Categoria	Volume	Review	Frete Médio	Atraso Médio (dias)
bed_bath_table	9.167	4,01★	R$ 18,65	-11,35 (adiantado)
health_beauty	8.608	4,24★	R$ 19,21	-11,96
sports_leisure	7.491	4,23★	R$ 19,64	-11,84
computers_accessories	6.501	4,08★	R$ 18,93	-12,36
furniture_decor	6.213	4,07★	R$ 21,34	-12,28

Nota: atraso médio negativo significa que os produtos chegam antes da data estimada — a estimativa de entrega é conservadora, o que protege a satisfação do cliente.

4.3 Análise de Coorte (Cohort Retention)

A análise de coorte revelou que a retenção de clientes cai para **0–1% já no primeiro mês após a compra inicial** em praticamente todas as coortes analisadas (Set/2016 – Ago/2018). O e-commerce brasileiro opera predominantemente com clientes de compra única, o que representa um desafio estrutural de LTV (Lifetime Value).

4.4 Mapa de Correlações

Variável	Correlação com Satisfação
Lead Time (dias)	**-0,33** ← maior impacto negativo
Atraso na Entrega	**-0,27**
Frete	-0,03
Preço	-0,03

O Lead Time é o fator logístico com maior influência na satisfação — mais relevante até que o valor do frete ou o preço do produto. Esse resultado reforça o direcionamento estratégico de priorizar velocidade de entrega sobre redução de preço.

---

5. Modelos de Machine Learning (Notebook 03)

5.1 Modelo 1 — Classificação: Previsão de Ruptura Logística

Algoritmo: Random Forest Classifier (`n_estimators=200`, `max_depth=12`, `min_samples_leaf=10`) **Problema:** prever se um pedido vai atrasar (`is_late = 1`) antes que o atraso ocorra.

Métrica	Resultado
Acurácia geral	**96,68%**
F1-Score médio (CV 5x)	**0,715 ± 0,011**
Precisão — classe Atrasado	82%
Recall — classe Atrasado	64%

A feature mais importante é o **Lead Time** com 83,1% de relevância — o modelo aprende que pedidos com ciclo logístico longo têm maior probabilidade de atrasar. O recall de 64% para a classe minoritária (apenas 6,7% dos pedidos atrasam) é resultado esperado do desbalanceamento de classes.

Aplicação prática: o modelo pode ser usado como sistema de alerta precoce — ao receber um pedido com características de alto risco, a equipe operacional pode acionar antecipação logística.

5.2 Modelo 2 — Regressão: Previsão de Satisfação do Cliente

Algoritmo: Random Forest Regressor (mesmos hiperparâmetros) **Problema:** prever o review score (1–5★) com base em dados operacionais e logísticos.

Métrica	Modelo	Baseline (média 4,16★)
MAE	**0,878**	1,008
RMSE	**1,146**	—
R^2	**0,220**	0,000
Melhoria vs baseline	**+13,0%**	—

O modelo explica 22% da variação de satisfação usando exclusivamente dados logísticos e operacionais. O R^2 relativamente baixo é esperado e cientificamente honesto: satisfação humana depende de fatores não capturados neste dataset (qualidade percebida do produto, expectativa prévia, experiência subjetiva). A feature mais importante é o **atraso em dias**, consistente com o resultado do heatmap de correlações do Notebook 02.

---

6. Conclusões Consolidadas

6.1 Resposta às questões de negócio

P1: A inflação impacta as vendas no curto prazo? Não há evidência de correlação direta no período analisado. O crescimento do e-commerce e a sazonalidade explicam melhor as variações de volume.

P2: Existe um "Custo Nordeste" mensurável? Sim. Pernambuco apresenta lead time 116% superior e frete 107% mais caro que São Paulo. Para empresas com clientes no Nordeste, essa diferença representa risco real de ruptura e insatisfação.

P3: Quais segmentos têm maior risco? Os segmentos "Em Risco" (23.188 clientes) e "Perdidos" (5.900 clientes) somam quase 31% da base — clientes com histórico de compra mas que pararam de comprar. São candidatos prioritários a ações de reativação.

P4: É possível prever ruptura e insatisfação? Sim. O modelo de classificação identifica 64% dos casos de atraso com 82% de precisão. O modelo de regressão erra em média 0,88 pontos na escala de satisfação, superando o baseline em 13%.

6.2 Priorização de ações

Prioridade	Ação	Impacto Esperado
🔴 Alta	Otimizar logística para destinos NE	Reduzir lead time e aumento de review score
🔴 Alta	Implantar modelo de alerta de ruptura	Detectar 64% dos atrasos antes de ocorrerem
🟡 Média	Programa de reativação RFM (Em Risco)	Recuperar receita de 23k clientes sem custo de aquisição
🟡 Média	Monitorar categorias com frete alto	Prevenir insatisfação em furniture_decor e auto
🟢 Longo prazo	Programa de fidelização (loyalty)	Aumentar LTV — retenção pós-coorte próxima de zero

---

7. Limitações e Próximos Passos

Limitações

- Dados históricos de 2016–2018: dinâmica atual do e-commerce pode diferir
- Modelo de regressão não inclui atributos qualitativos do produto
- Análise de coorte limitada ao período do dataset (26 meses)

- Classe "Atrasado" desbalanceada (6,7%) — afeta o recall do Modelo 1

Próximos passos técnicos

1. Aplicar `SMOTE` para balancear classe minoritária no Modelo 1
2. Comparar RandomForest com `XGBoost` e `LightGBM`
3. `GridSearchCV` para otimização de hiperparâmetros
4. Incluir variáveis de peso/dimensão dos produtos como features
5. Deploy de API de scoring em tempo real via `FastAPI` + `joblib`
6. Integrar dados de marketing funnel (dataset complementar da Olist)

---

8. Estrutura do Projeto

```
inteligencia-varejo-dinamica-consumo/
├── data/
│   └── raw/                  ← CSVs brutos da Olist
├── notebooks/
│   ├── 01_analise_inteligencia_varejo.ipynb   ← EDA: Inflação e Logística
│   ├── 02_analise_avancada_clientes.ipynb     ← RFM, Coorte, Categorias
│   └── 03_modelos_machine_learning.ipynb      ← Classificação + Regressão
├── reports/
│   ├── relatorio_geral.md         ← este documento
│   ├── resumo_executivo.md        ← para gestores e recrutadores
│   └── resumo_tecnico.md          ← para equipes técnicas
└── requirements.txt
```

Projeto desenvolvido como portfólio de análise de dados aplicada ao varejo brasileiro. Dataset: Brazilian E-Commerce Public Dataset by Olist (Kaggle) — licença CC BY-NC-SA 4.0