INTELIGÊNCIA DE VAREJO

Dados, Logística e Machine Learning

Rafael Dutra

Análise do e-commerce brasileiro
(Olist + IPCA/IBGE)

CONTEXTO E OBJETIVO

MISSÃO PRINCIPAL

Analisar o impacto da **inflação (IPCA)** e **falhas logísticas** no Sell-out e na experiência do consumidor brasileiro.

FONTES DE DADOS

Dataset público da **Olist** combinado com dados oficiais do **IBGE** via API em tempo real.

JANELA TEMPORAL

Análise abrangente cobrindo o período de **Janeiro/2016 a Agosto/2018**.

METODOLOGIA E PIPELINE DE DADOS

96.478 PEDIDOS ENTREGUES ANALISADOS NO ECOSSISTEMA OLIST

FASE 01

Extração

Consumo de CSVs brutos da Olist e integração via API REST com a Tabela 1737 do IBGE/SIDRA.

FASE 02

Transformação

Criação de KPIs logísticos, filtro de integridade (delivered) e normalização temporal para join com IPCA.

FASE 03

Carga

Consolidação em DataFrame analítico único com 19 colunas para exploração e modelagem.

LOGÍSTICA VS. INFLAÇÃO

A análise revelou que o **Lead Time** é o fator logístico com maior influência na satisfação, superando variáveis macroeconômicas.

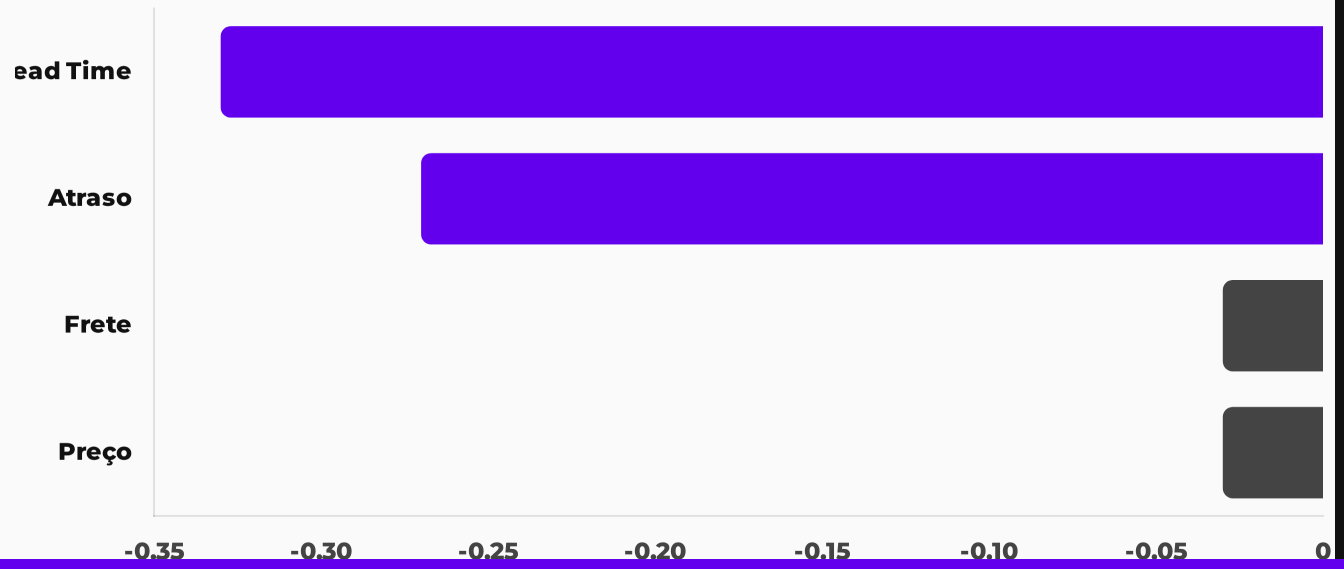

-0,33

CORRELAÇÃO LEAD TIME VS SATISFAÇÃO

Não há evidência de correlação direta entre o IPCA e o volume de vendas no curto prazo. O desempenho é ditado pela eficiência operacional e sazonalidade.

DISPARIDADE LOGÍSTICA

O "Custo Nordeste" em números

LEAD TIME MÉDIO

17,96 dias

+116%

TEMPO

vs 8,30 dias em São Paulo

FRETE MÉDIO

R$ 35,83

+107%

CUSTO

vs R$ 17,33 em São Paulo

A concentração de sellers no Sudeste gera uma desvantagem estrutural severa para o Nordeste, elevando o risco de ruptura e insatisfação.

O IMPACTO DA RUPTURA LOGÍSTICA

-47%

NA SATISFAÇÃO

Um atraso na entrega quase divide a nota de satisfação ao meio, sendo o principal destruidor de experiência no e-commerce.

ENTREGA NO PRAZO

4.29★

ENTREGA COM ATRASO

2.27★

SEGMENTAÇÃO DE CLIENTES (RFM)

~50%

DA BASE EM RISCO OU PERDIDA

SEGMENTO	CLIENTES	% BASE	TICKET MÉDIO
Campeões	23.491	25,1%	R$ 147
Clientes Recentes	23.356	25,0%	R$ 138
Em Risco	23.188	24,8%	R$ 143
Potencial	17.423	18,6%	R$ 148
Perdidos	5.900	6,3%	R$ 138

Insight: Quase 30 mil clientes representam receita latente não capturada. Estratégias de reativação via e-mail marketing e cupons podem recuperar este volume sem custo de aquisição (CAC).

DESAFIO ESTRUTURAL DE LTV

0-1%

RETENÇÃO APÓS O 1º MÊS

ANÁLISE DE COORTE

A retenção de clientes cai drasticamente logo após a compra inicial, revelando um mercado de **compradores únicos**.

SAÚDE DAS CATEGORIAS

Apesar da baixa retenção, as **Top 10 categorias** mantêm review score **> 4,0★**, indicando uma operação saudável.

IMPLICAÇÃO DE NEGÓCIO

O e-commerce brasileiro opera com um desafio estrutural de **Lifetime Value**, exigindo foco constante em aquisição ou fidelização.

PREVISÃO DE RUPTURA LOGÍSTICA

96,7%
ACURÁCIA GERAL

82%
PRECISÃO (ATRASO)

64%
RECALL (ATRASO)

ALGORITMO

Random Forest Classifier

Aplicação Prática: Sistema de alerta precoce para identificar pedidos com alto risco de atraso antes que a ruptura ocorra.

FEATURE PRINCIPAL: LEAD TIME **83,1%**

O modelo confirma que o ciclo logístico longo é o maior preditor de falhas na entrega.

PREVISÃO DE SATISFAÇÃO DO CLIENTE

0,878
MAE (ERRO MÉDIO)

+13%
VS BASELINE

22%
R^2 (VARIÂNCIA)

ALGORITMO

Random Forest Regressor

Objetivo: Prever o Review Score (1-5★) com base em dados operacionais e logísticos.

VARIÁVEL CRÍTICA: ATRASO EM DIAS

O modelo confirma que o **atraso real** é o maior preditor de insatisfação. O R^2 de 22% reflete a natureza subjetiva da satisfação, que depende de fatores externos como a **qualidade intrínseca** do produto.

ROTEIRO ESTRATÉGICO

PRIORIZAÇÃO DE AÇÕES

ALTA PRIORIDADE

Otimização Logística NE

Reduzir Lead Time para destinos críticos e implantar modelo de alerta de ruptura (ML).

MÉDIA PRIORIDADE

Reativação RFM

Recuperar receita de 29k clientes em risco/perdidos via campanhas de baixo custo.

MÉDIA PRIORIDADE

Monitoramento de Frete

Atuar em categorias com frete desproporcional para proteger a margem e satisfação.

LONGO PRAZO

Programa de Fidelidade

Implementar estratégias de retenção pós-coorte para elevar o Lifetime Value (LTV).

CONCLUSÃO GERAL

A **eficiência logística** é o principal driver de performance no e-commerce brasileiro, sendo mais relevante para a satisfação do que fatores macroeconômicos como a inflação.

PRÓXIMOS PASSOS TÉCNICOS

01 Aplicar **SMOTE** para balancear a classe de atrasos no Modelo de Classificação.

02 Testar algoritmos de boosting como **XGBoost** e **LightGBM** para melhorar o Recall.

03 Implementar **GridSearchCV** para otimização fina de hiperparâmetros.

04 Deploy de API de scoring em tempo real via **FastAPI + Joblib**.