Resumo Técnico

Projeto: Inteligência de Varejo — Pipeline de Dados, Modelos e Métricas

Stack: Python 3.11 | Pandas 3.0.1 | Scikit-learn | Seaborn | Matplotlib | Sidrapy | Requests
Ambiente: Jupyter Notebook (.venv isolada) | Dados brutos em `data/raw/`

---

1. Arquitetura do Pipeline de Dados

Fontes

- **Olist Dataset** (7 CSVs): `orders`, `order_items`, `order_reviews`, `customers`, `products`, `product_category_name_translation`, `sellers`
- **IBGE/SIDRA API REST**: Tabela 1737 — IPCA variação mensal (Jan/2016–Dez/2018)

ETL (Extract → Transform → Load)

```
[CSV brutos]  →  filtro status=delivered  →  parse datetime
              →  KPIs: delivery_delay_days, lead_time_days
              →  merge: customers + reviews + order_items + products
              →  chave temporal AnoMes (YYYY-MM)
              →  join com IPCA via AnoMes
              →  [DataFrame analítico: 96.478 pedidos | 19 colunas]
```

Feature Engineering aplicada

Feature	Cálculo	Uso
`delivery_delay_days`	`delivered_date - estimated_date`	Ruptura, ML
`lead_time_days`	`delivered_date - purchase_date`	Logística, ML
`AnoMes`	`YYYY-MM` via `dt.to_period('M')`	Join com IPCA
`mes_compra`	`dt.month`	Sazonalidade ML
`dia_semana_compra`	`dt.dayofweek`	Sazonalidade ML
`is_late`	`delivery_delay_days > 0` → 0/1	Target classificação

---

2. Notebook 01 — EDA: Inflação e Logística Regional

Resultados quantitativos

Métrica	PE	SP	Δ
Lead Time médio (dias)	17,96	8,30	+116%
Frete médio (R$)	35,83	17,33	+107%

Status Entrega	Review Score médio
Atrasado (Ruptura)	2,27★
No Prazo	4,29★

- **IPCA × Volume de Vendas:** sem correlação consistente no curto prazo. Sazonalidade e crescimento do e-commerce explicam melhor as oscilações.

---

3. Notebook 02 — Segmentação e Análise Avançada

3.1 Segmentação RFM

- **Data de referência:** 1 dia após `2018-10-17` (último pedido do dataset)
- **Scoring:** quartis Q1–Q4 via `pd.qcut`, com ranking para F (rank method='first')
- **Base analisada:** 93.358 clientes únicos

Segmento	N	%	Ticket Médio
Campeões	23.491	25,1%	R$147
Clientes Recentes	23.356	25,0%	R$138
Em Risco	23.188	24,8%	R$143
Potencial	17.423	18,6%	R$148
Perdidos	5.900	6,3%	R$138

3.2 Top 10 Categorias

Categoria	Volume	Review	Frete Médio
bed_bath_table	9.167	4,01★	R$18,65

health_beauty	8.608	4,24★	R$19,21
sports_leisure	7.491	4,23★	R$19,64
computers_accessories	6.501	4,08★	R$18,93
furniture_decor	6.213	4,07★	R$21,34

Todas as top 10 categorias mantêm review ≥ 4,0★.

3.3 Análise de Coorte

- **Método:** cohort por mês da primeira compra → período relativo via subtração de `Period`
- **Resultado:** retenção cai para 0–1% já no período 1 em todas as coortes
- **Interpretação:** perfil de compra única predominante — baixo LTV recorrente

3.4 Heatmap de Correlações

Par	r de Pearson	Interpretação
Lead Time × Satisfação	**-0.33**	correlação mais forte
Atraso × Satisfação	**-0.27**	impacto direto
Frete × Lead Time	**+0.22**	frete alto acompanha entrega longa
Preço × Frete	**+0.40**	itens caros têm frete maior
Preço × Satisfação	**-0.03**	impacto negligenciável
Frete × Satisfação	**-0.03**	impacto negligenciável

---

4. Notebook 03 — Machine Learning

Dataset ML

- **Registros após limpeza:** 95.824
- **Proporção de atrasos (target classe 1):** 6,7% — desbalanceado
- **Split:** 80/20 estratificado (`random_state=42`)

Modelo 1 — Random Forest Classifier (Previsão de Ruptura)

```
Hiperparâmetros: n_estimators=200 | max_depth=12 | min_samples_leaf=10
```

Métrica	Valor

Acurácia	**96.68%**
F1-Score (CV 5x)	**0.715 ± 0.011**
Precisão — Atrasado	82%
Recall — Atrasado	64%
F1 — Atrasado	0.72

Feature Importance:

Feature	Importância
Lead Time (dias)	**83,1%**
Valor do Frete	~5%
Demais features	<5% cada

Observação técnica: o alto recall da classe "No Prazo" (99%) e baixo recall de "Atrasado" (64%) é esperado em datasets desbalanceados. Melhoria possível com SMOTE ou `class_weight='balanced'`.

Modelo 2 — Random Forest Regressor (Previsão de Review Score)

```
Hiperparâmetros: n_estimators=200 | max_depth=12 | min_samples_leaf=10
Features: FEATURES_ML + ['delivery_delay_days']
```

Métrica	Modelo	Baseline (média)
MAE	**0.878**	1.008
RMSE	**1.146**	—
R^2	**0.220**	0.000
Melhoria vs baseline	**+13.0%**	—

Feature mais importante: `delivery_delay_days` (atraso em dias)

Limitação documentada: R^2=0.22 é esperado para predição de comportamento humano com dados exclusivamente operacionais. Preço e frete têm correlação com satisfação próxima de zero (-0.03), confirmando que o teto do modelo com essas features é estrutural.

---

5. Próximos Passos Técnicos

1. `GridSearchCV` para otimização de hiperparâmetros
2. Comparar RandomForest com `XGBoostClassifier` e `LightGBM`
3. Aplicar `SMOTE` para balancear classe "Atrasado" no Modelo 1
4. Incluir variáveis de produto (peso, dimensões) como features
5. Deploy de scoring via `FastAPI` + `joblib` para inferência em tempo real